

Гипотезы

Майнор ИАД, 20 февраля 2020 г.

Денис Деркач

Лаборатория Lambda, ФКН ВШЭ

Оглавление

Понятие статистической гипотезы

Статистический критерий

Параметрические тесты

t-тест

Непараметрические тесты

χ^2 тест

Критерий Манна-Уитни


Критерий перестановок

Бутстрэп

Понятие статистической гипотезы

Мотивирующий пример

- › В первой группе — 26 студентов, а во второй — 24. Средний балл за тест №1 в первой группе 4.4 балла, во второй — 2.81.



- › Что можно спрашивать об этих данных?

Понятие статистической гипотезы

Определение

Статистическая гипотеза — определённое предположение о распределении вероятностей, лежащем в основе наблюдаемой выборки данных.

- › **Простая гипотеза** однозначно определяет функцию распределения на рассматриваемом множестве.
 - › **Пример:** $\theta = \theta_0$ — простая гипотеза.
- › **Сложная гипотеза** утверждает принадлежность распределения к некоторому множеству распределений на рассматриваемом множестве.
 - › **Пример:** $\theta > \theta_0$ или $\theta < \theta_0$ — сложная гипотеза.

Проверка статистической гипотезы

Определение


Проверка статистической гипотезы — это процесс принятия решения о том, противоречит ли рассматриваемая статистическая гипотеза наблюдаемой выборке данных.

Всегда рассматривается задача проверки:

- › нулевой гипотезы H_0 ;
- › против альтернативной гипотезы H_1 .

Пример

- › В первой группе — 26 студентов, а во второй — 24. Средний балл за тест №1 в первой группе 4.4 балла, во второй — 2.81.



- › H_0 : студенты в обеих группах одинаково знают материал;
- › H_1 : студенты знают материал по-разному.

Формулировки и правила

- › мы говорим про "отклонение H_0 ", "принятие H_1 " не рассматривается;
- › мы говорим "имеющихся количества данных недостаточно для отклонение H_0 ";
- › мы тестируем только пару $(H_0; H_1)$ и ничего не знаем о неописанных состояниях системы:
 - › пример: контрольная работа была слишком простая и студенты получили максимум.

Статистический критерий

Статистический критерий

Определение

Статистический критерий — правило, по которому на основании реализации выборки (x_1, x_2, \dots, x_n) , принимается или отвергается статистическая гипотеза.

Обычно критерий задаётся при помощи статистики критерия $T(x_1, x_2, \dots, x_n)$.

Пример: взболтать, но не смешивать

- › Джеймс Бонд говорит, что предпочитает martini взболтанным, но не смешанным.
- › Проведём слепой тест: предложим ему n раз пару напитков и спросим, какой из двух он предпочитает
- › Выборка: объём из n нулей и единиц (предпочёл взболтанный — 1, смешанный — 0), получается вектор.
- › Нулевая гипотеза: Джеймс Бонд выбирает наугад.
- › Статистика: число единиц в выборке.

Векторы
для $n=2$:


0	0
0	1
1	0
1	1



Статистика шотов


- › Если нулевая гипотеза справедлива и Джеймс Бонд не различает напитки, то все исходы равновероятны.
- › Пусть $n = 16$ — тогда существует 65535 различных бинарных исходов.

Распределение количества единиц в векторе исходов.




Эксперимент

- › Провели эксперимент — Джеймс Бонд выбрал взболтанный martini в 12 из 16 раз.
- › Вероятность того, что он выберет взболтанный martini 12 раз или больше при условии, что выбирает наугад: $2512/65536 \approx 0.0384$
- › Отклоняем ли мы гипотезу о том, что Джеймс Бонд не разбирается в martini?



р-значение




Определение

р-значением называется вероятность того, что статистика может быть такой или более экстремальной при верной нулевой гипотезе.

В примере с Бондом мы уже её подсчитали.

Типы критериев



- › Односторонний критерий


$$H_0 : \theta \leq \theta_0 \text{ vs } H_1 : \theta > \theta_0.$$

- › Двусторонний критерий

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta \neq \theta_0.$$

Эксперимент

- › Провели эксперимент — Джеймс Бонд выбрал взболтанный martini в 12 из 16 раз.
- › Вероятность того, что он выберет взболтанный martini 12 раз или больше при условии, что выбирает наугад: $2512/65536 \approx 0.0384$
- › Отклоняем ли мы гипотезу о том, что Джеймс Бонд не разбирается в martini?



Критическая область

Нам надо заранее задать значения статистики, где гипотеза будет отклонена.

Определение


- › χ_0 — область принятия гипотезы H_0 ,
- › χ_1 — область ее отклонения (критическая область).

Говорят, что критерий имеет уровень значимости α , если

$$\mathbb{P}(T \in \chi_1 | \mathbb{H}_0) \leq \alpha.$$

Эксперимент

- › Провели эксперимент — Джеймс Бонд выбрал взболтанный martini в 12 из 16 раз.
- › Вероятность того, что он выберет взболтанный martini 12 раз или больше при условии, что выбирает наугад: $2512/65536 \approx 0.0384$
- › Отклоняем ли мы гипотезу о том, что Джеймс Бонд не разбирается в martini?
- › Да, если заранее определили уровень значимости $\alpha = 0.05$.



Ход проверки гипотез

1. Формулируем задачу.
2. Формулируем нулевую и альтернативную гипотезу.
3. Задаём критическое значение.
4. Ищем нужный статистический критерий.
5. Ищем правильное распределение статистического критерия.
6. Проводим измерение.
7. Ищем p -значение.
8. Сравниваем его с критическим значением.
9. Делаем вывод.

Проблемы использования p -значений

p -значение очень часто неправильно интерпретируется как что-то полностью описывающее эксперимент.

- Don't base your conclusions solely on whether an association or effect was found to be "statistically significant" (i.e., the p -value passed some arbitrary threshold such as $p < 0.05$).
- Don't believe that an association or effect exists just because it was statistically significant.
- Don't believe that an association or effect is absent just because it was not statistically significant.
- Don't believe that your p -value gives the probability that chance alone produced the observed association or effect or the probability that your test hypothesis is true.
- Don't conclude anything about scientific or practical importance based on statistical significance (or lack thereof).

Don't. Don't. Just...don't. Yes, we talk a lot about don'ts. The ASA

Внимательно следите за тем, как вы интерпретируете результаты эксперимента.

Ошибки

Следуя любому критерию мы можем принять правильное решение, либо совершить одну из двух ошибок — первого или второго рода.

		Верная гипотеза	
		H_0	H_1
Результат применения	H_0	ОК	ошибка 2-го рода
критерия	H_1	ошибка 1-го рода	ОК

Примеры

H_0 : not-pregnant!

Type I Error



Type II Error



Мощность теста

Определение

Мощность критерия показывает вероятность попадания значения критерия T в критическую область, когда F — ее истинное распределение.

Чем мощнее критерий, тем лучше для нас. В идеале мы должны использовать самый мощный критерий.

Выбор критерия

- › Логично стремление построить критерий так, чтобы свести к минимуму вероятности ошибок обоих типов.
- › Однако при фиксированном объеме выборки сумма вероятностей ошибок обоих типов не может быть сделана сколь угодно малой.
- › Поэтому руководствуются рациональным принципом выбора критической области.

Из всех критических областей удовлетворяющих заданному уровню значимости выбирается та, для которой вероятность ошибки 2-го рода минимальна.

Параметрические тесты

Описание критерия

- › В примере с Бондом мы просчитывали все возможные варианты.
- › В реальной жизни это сделать трудно.
- › Зато у нас есть некоторые соображения как правильно выбирать критерии под конкретную задачу. Это автоматически будет давать нужные распределения.

Типы критериев

- › Одновыборочные: например, среднее равно нулю.
- › Двухвыборочные: например, среднее одной выборки равно среднему другой.
- › Согласия: например, эта кривая хорошо описывает выборку.
- › Распределения: например, эта выборка из нормального распределения.

Критерий Стьюдента

- › Пусть $X, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, где (μ, σ^2) неизвестны.
- › Задача

$$\mathbb{H}_0 : \mu = \mu_0 \text{ vs. } \mathbb{H}_1 : \mu \neq \mu_0$$

- › Обозначим через S_n^2 выборочную дисперсию. Статистика критерия:

$$T = \frac{\sqrt{n}(\overline{X}_n - \mu_0)}{S_n}$$

- › Основная гипотеза отвергается, если $|T| > t_{n-1, \alpha/2}$, где $t_{n-1, \alpha/2}$ — квантиль распределения Стьюдента с $n - 1$ степенями свободы.
- › При больших n выполняется $T \sim \mathcal{N}(0, 1)$, то есть при больших n t-критерий эквивалентен критерию Вальда.

Критерий Стьюдента (t-test)




Рис.: https://ru.wikipedia.org/wiki/Распределение_Стьюдента

Критерий Стьюдента (t-test)




Рис.: <http://tananyag.geomatech.hu/m/53882>

Двухвыборочный t-критерий

› $\{X_i\}_{i=1}^n, \{Y_j\}_{j=1}^m$ — две выборки из нормальных распределений $\mathcal{N}(\mu_X, \sigma_X^2), \mathcal{N}(\mu_Y, \sigma_Y^2)$

› Задача

$$\mathbb{H}_0 : \mu_X = \mu_Y \quad \text{vs.} \quad \mathbb{H}_1 : \mu_X \neq \mu_Y$$

› Механика проверки гипотезы та же, что и раньше.

Непараметрические тесты

Непараметрические тесты

- › Параметрические тесты хороши, когда известны распределения выборки.
- › Например, t-тест работает для нормального распределения.
- › Для остальных случаев есть непараметрические тесты.


χ^2 тест Пирсона

- › Тест согласия с распределением/функцией.
- › Составляется как


$$\chi^2 = N \sum_{i=1}^n \frac{(O_i/N - p_i)^2}{p_i}.$$

здесь N - количество событий всего, O_i - количество событий в этой точке, p_i ожидаемая частота событий.

- › распределено как χ^2 с $N - 1$ степенью свободы.



Ненормальность данных



- › Иногда нам нужно сравнить две выборки, которые явно ненормальны.
- › t-тест не работает, что делать?
- › Использовать критерий Манна-Уитни-Вилкоксона.

Критерий Манна-Уитни-Вилкоксона

1. Выстроить обе выборки в одну.
2. Присвоить номер по возрастанию.
3. Найти средний номер в выборках (R_1 или R_2).
4. Подсчитать:

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2}$$

$$U_2 = R_2 - \frac{n_2(n_2 + 1)}{2}$$

5. Получить критическое значение (U распределение, для больших семплов, нормальное), сравнить с p -value.

NB: Этот критерий сравнивает распределения, а не средние.

Критерий перестановок:

1. Обозначим через $T(x_1, \dots, x_m, y_1, \dots, y_n)$ некоторую тестовую статистику, например, $T(X_1, \dots, X_m, Y_1, \dots, Y_n) = |\bar{X}_m - \bar{Y}_n|$.
2. Положим $N = m + n$ и рассмотрим все $N!$ перестановок объединенной выборки $X_1, \dots, X_m, Y_1, \dots, Y_n$.
3. Для каждой из перестановок подсчитаем значение статистики T .
4. Обозначим эти значения $T_1, \dots, T_{N!}$.

Если \mathbb{H}_0 верна, то при фиксированных упорядоченных значениях $\{X_1, \dots, X_m, Y_1, \dots, Y_n\}$ значение статистики T распределены равномерно на множестве $T_1, \dots, T_{N!}$.

Критерий перестановок

Для критерия перестановок количество более критических значений и есть p -значения.

$$p\text{-value} = P(T > t_{obs}) = \frac{1}{N!} \sum_{j=1}^{N!} \mathbb{I}(T_j > t_{obs})$$

Критерий перестановок: пример

- › Пусть $(X_1, X_2, Y_1) = (1, 9, 3)$.
- › Пусть $T(X_1, X_2, Y_1) = |\bar{X} - \bar{Y}| = 2$, тогда

Перестановка	Значение T	Вероятность
(1,9,3)	2	1/6
(9,1,3)	2	1/6
(1,3,9)	7	1/6
(3,1,9)	7	1/6
(3,9,1)	5	1/6
(9,3,1)	5	1/6

- › $p\text{-value} = P(T > 2) = 4/6$.

Бутстрэп и Гипотезы

- › В критерии перестановок мы просто перемешивали события.
- › В принципе, мы можем вытаскивать произвольные события с возвращением и получать новые выборки.
- › Это будет бутстрэпным тестом.

Финальный слайд

- › Тестирование гипотез — центральная задача статистики.
- › Для каждой задачи скорее всего есть специальный тест, нужно его просто сформулировать.